ANO
2026

UNINTER

CADERNO DE RESPOSTAS DA ATIVIDADE PRÁTICA DE:

PROJETOS BIG DATA

ALUNO: LUIGI FRANCESCO FEDELE - 4517608

Caderno de Resposta Elaborado por:
Prof. MSc. Guilherme Ditzel Patriota

Prática 01 – Somatório de IDs

Questão – Qual o valor da soma de todos os campos “id” dos filmes classificados como negativos para o banco de dados “imdb-reviews-pt-br.csv”

ENUNCIADO: Nessa prática você deverá descobrir, utilizando sua máquina virtual com o Hadoop ou Spark ou PySpark, qual o valor da soma de todos os campos “id” dos filmes classificados como negativos para o banco de dados “imdb-reviews-pt-br.csv”.

I. Apresentação do Código (não esquecer do identificador pessoal):

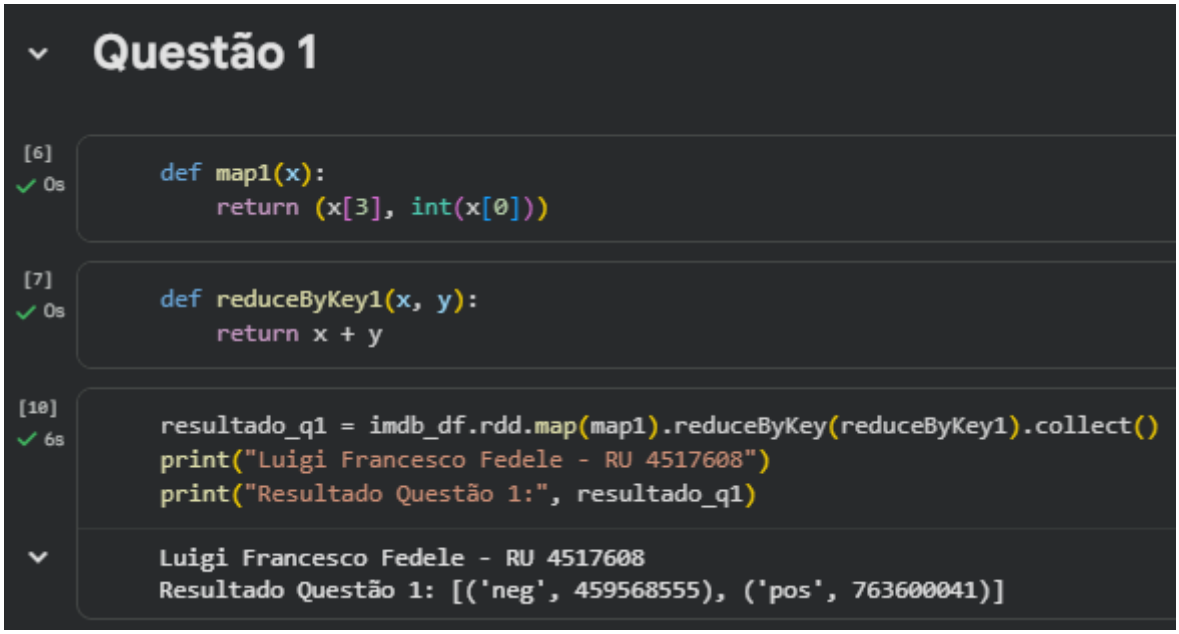


Figura 1: Apresentação do código no google colab

II. Apresentação das Imagens/Print do resultado (não esquecer do identificador):

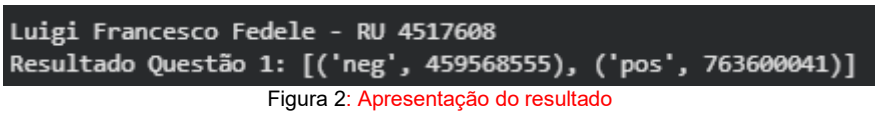


Figura 2: Apresentação do resultado

III. Responda à pergunta: Qual o valor da soma de todos os campos “id” dos filmes classificados como negativos?

Resposta: 459568555

Prática 02 – Diferença do número de palavras totais de português para inglês dos textos negativos

Questão – Contar palavras dos textos negativos e achar diferença de quantidade.

ENUNCIADO: Nessa prática você deverá contar todas as palavras existentes nos textos negativos (Português e Inglês) e então deverá encontrar quantas palavras a mais, no total, os textos em português possuem.
Para tal, crie um script em Python ou Scala e rode-o com sua máquina virtual Hadoop ou Spark ou PySpark, como feito na prática 1.
É necessário se preocupar em filtrar corretamente as avaliações de filmes para que apenas os textos marcados como negativos sejam contabilizados.

I. Apresentação do Código (não esquecer do identificador pessoal):

Questão 2

```
[11] 0s
def map2(x):
    # x[1] é text_en, x[2] é text_pt, x[3] é sentiment
    palavras_en = len(x[1].split()) if x[1] else 0
    palavras_pt = len(x[2].split()) if x[2] else 0
    return (x[3], (palavras_en, palavras_pt))

[12] 0s
def reduceByKey2(x, y):
    return (x[0] + y[0], x[1] + y[1])

[13] 8s
resultado_q2 = imdb_df.rdd.map(map2).reduceByKey(reduceByKey2).collect()
print("Resultado Questão 2:", resultado_q2)

Resultado Questão 2: [('neg', (5400324, 5455273)), ('pos', (5414747, 5462204))]

[18] 0s
for sentiment, (total_en, total_pt) in resultado_q2:
    if sentiment == 'neg':
        diferenca = total_pt - total_en
        print(f"Total palavras Inglês (negativo): {total_en}")
        print(f"Total palavras Português (negativo): {total_pt}")
        print(f"Diferença (Português - Inglês): {diferenca}")

Total palavras Inglês (negativo): 5400324
Total palavras Português (negativo): 5455273
Diferença (Português - Inglês): 54949
```

Figura 3: Apresentação do código no google colab

II. Apresentação das Imagens/Print do resultado (não esquecer do identificador):

```
Total palavras Inglês (negativo): 5400324
Total palavras Português (negativo): 5455273
Diferença (Português - Inglês): 54949
```

Figura 4: Apresentação da diferença entre palavras inglês e português

III. **Responda à pergunta: Qual o número total de palavras a mais que os textos negativos em português possuem em comparação com a soma total das palavras dos textos negativos em inglês, independentemente de serem repetidas?**

Resposta: 54949